

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Báo cáo đồ án cuối kì

Đề tài: Emotion Recognition App

Môn học: Học thống kê - CSC15004

Sinh viên thực hiện:

Võ Trần Duy Hoàng - 23120266

Trương Sỹ Khánh - 23120284

Lê Công Phúc - 23120330

Giảng viên hướng dẫn:

Ngô Minh Nhựt

Lê Long Quốc

Ngày 30 tháng 5 năm 2026

Mục lục

1	Tổng quan về hệ thống nhận diện cảm xúc văn bản	1
2	Mô tả tập dữ liệu thực nghiệm	1
3	Quy trình tiền xử lý dữ liệu (Dataset Preprocessing)	2
4	Kiến trúc RoBERTa cho nhận diện cảm xúc	4
4.1	Phân mảnh từ vừng và mã hóa token	5
4.2	Tầng nhúng và biểu diễn không gian (Embedding Layer)	6
4.3	Cơ chế Multi-Head Self-Attention	6
4.4	Đầu phân loại chuỗi	7
5	Thiết kế thực nghiệm và tối ưu hóa siêu tham số	7
5.1	Thiết lập Baseline Hyperparameters	7
5.2	Hyperparameter Tuning	8
5.3	Model Training	9
6	Kết quả thực nghiệm và phân tích đánh giá	10
7	Triển khai hệ thống và vận hành thực tế	12
7.1	Triển khai giao diện người dùng	12
7.2	Triển khai Backend API	13
7.3	Triển khai dịch vụ mô hình học máy	13
7.4	Cơ sở dữ liệu và hàng đợi xử lý	14
7.5	Kiến trúc triển khai tổng thể	14
8	Kết luận	14
9	References	15

1 Tổng quan về hệ thống nhận diện cảm xúc văn bản

Text-based Emotion Recognition là một bài toán phân loại đa lớp có độ phức tạp cao trong lĩnh vực Natural Language Processing - NLP. Khác với sentiment analysis thường chỉ tập trung vào phân cực nhị phân hoặc tam phân như tích cực, tiêu cực và trung tính, nhận diện cảm xúc yêu cầu hệ thống bóc tách được các trạng thái tâm lý đa dạng, tinh tế và phụ thuộc mạnh vào ngữ cảnh giao tiếp của con người.

Trong bối cảnh các mô hình ngôn ngữ lớn (LLMs) dựa trên kiến trúc Transformer ngày càng đạt hiệu năng cao trong các tác vụ NLP, đồ án lựa chọn hướng tiếp cận học sâu để xây dựng hệ thống phân loại cảm xúc văn bản. Cụ thể, mô hình nền tảng được sử dụng là RoBERTa (*Robustly Optimized BERT Approach*), một biến thể cải tiến từ BERT thông qua việc tối ưu hóa chiến lược pre-training, loại bỏ tác vụ dự đoán câu tiếp theo (*Next Sentence Prediction*), sử dụng cơ chế Dynamic Masking và huấn luyện trên quy mô dữ liệu lớn hơn.

Mục tiêu của hệ thống là nhận một câu văn tiếng Anh ở dữ liệu đầu vào và tự động phân loại câu đó vào một trong sáu nhãn cảm xúc: *sadness*, *joy*, *love*, *anger*, *fear* và *surprise*. Việc fine-tuning RoBERTa trên dữ liệu Twitter tiếng Anh giúp mô hình học được các đặc trưng ngôn ngữ phi cấu trúc, tiếng lóng và sắc thái biểu cảm đặc thù của mạng xã hội. Bản báo cáo này trình bày chi tiết quá trình xây dựng mô hình, kết quả thực nghiệm đánh giá toán học.

2 Mô tả tập dữ liệu thực nghiệm

Thực nghiệm được triển khai trên tập dữ liệu [dair-ai/emotion](#) được lưu trữ công khai trên Hugging Face. Đây là tập hợp các thông điệp Twitter bằng tiếng Anh đã được gán nhãn thủ công theo sáu nhóm cảm xúc cơ bản của Paul Ekman, bao gồm: buồn bã (*sadness*), vui vẻ (*joy*), yêu thương (*love*), tức giận (*anger*), sợ hãi (*fear*) và ngạc nhiên (*surprise*). Mỗi mẫu dữ liệu gồm hai thuộc tính chính: văn bản gốc dạng chuỗi (`text`) và nhãn cảm xúc dạng số nguyên (`label`) được mã hóa từ 0 đến 5.

Trong đồ án, bộ dữ liệu được sử dụng ở cấu hình chưa phân tách (*unsplit*) với tổng cộng 416,809 mẫu. Toàn bộ dữ liệu ban đầu được chia thành ba phần phục vụ huấn luyện, đánh giá và kiểm thử. Quy trình phân tách được thực hiện qua hai bước:

- Tách 90% / 10%:** sử dụng phương thức `train_test_split(test_size=0.1, seed=42)` trên tập dữ liệu gốc. Kết quả thu được 375,128 mẫu cho tập huấn luyện chính thức `train_test['train']` và 41,681 mẫu cho tập trung gian `train_test['test']`.
- Chia đôi tập trung gian:** tiếp tục áp dụng `train_test_split(test_size=0.5, seed=42)` trên tập trung gian. Do tập trung gian chiếm 10% dữ liệu gốc, việc chia đôi tạo ra hai tập xấp xỉ 5% dữ liệu gốc: 20,840 mẫu cho tập đánh giá và 20,841 mẫu cho tập kiểm thử.

Bảng 1: Phân bổ tập dữ liệu trong quy trình thực nghiệm

Phân khúc dữ liệu	Số mẫu	Tỷ lệ	Vai trò
Train	375,128	90%	Cập nhật trọng số của mạng neural RoBERTa thông qua lan truyền ngược Backpropagation.
Validation	20,840	5%	Giám sát quá trình hội tụ, kiểm soát hiện tượng quá khớp overfitting và hỗ trợ điều chỉnh siêu tham số.
Test	20,841	5%	Đánh giá khách quan khả năng tổng quát hóa cuối cùng của mô hình trên dữ liệu chưa biết.

Phân phối nhân của tập dữ liệu có hiện tượng mất cân bằng lớp (*class imbalance*). Các lớp như *joy* và *sadness* thường chiếm tỷ trọng lớn hơn, trong khi *love* và đặc biệt là *surprise* có số lượng mẫu ít hơn. Sự chênh lệch này khiến quá trình huấn luyện trở nên khó khăn hơn vì mô hình có xu hướng ưu tiên các lớp đa số. Đòi hỏi mô hình học sâu phải có khả năng trích xuất đặc trưng cực kỳ nhạy bén để không bị bão hòa bởi các lớp đa số. Do đó, các chỉ số đánh giá như Macro F1-score cần được xem xét bên cạnh Accuracy để phản ánh công bằng hơn hiệu năng trên từng lớp cảm xúc.

3 Quy trình tiền xử lý dữ liệu (Dataset Preprocessing)

Dữ liệu thu thập từ các nền tảng mạng xã hội như Twitter mang tính chất phi cấu trúc rất cao, chứa nhiều thành phần nhiễu cấu trúc và các dạng từ ngữ phi chuẩn mực. Vì nhóm quyết định dùng mô hình RoBERTa cho bài toán này, nên để có thể tối ưu hóa không gian biểu diễn ngữ nghĩa cho mô hình này, toàn bộ 416,809 mẫu dữ liệu thuộc cấu hình chưa phân tách (unsplit) của bộ dữ liệu [dair-ai/emotion](#) phải trải qua một pipeline tiền xử lý sâu nghiêm ngặt trước khi đưa vào tầng nhúng của mạng neural. Quy trình này được thiết kế và triển khai tuần tự qua 5 giai đoạn cốt lõi sau:

Phase 1. Noise Removal

- Văn bản thô ban đầu được chuyển đổi hệ ký tự hoàn toàn về dạng chữ thường (lowercase) nhằm đồng bộ hóa định dạng hiển thị của từ vựng.
- Sử dụng Regular Expressions để bóc tách và loại bỏ các thành phần không đóng góp vào sắc thái cảm xúc cốt lõi bao gồm: liên kết cấu trúc (URL/Hyperlink), các thẻ HTML thô, thẻ đề cập người dùng dạng @username và các nhãn chủ đề mạng xã hội hashtag.
- Tiến hành lọc bỏ toàn bộ các ký tự đặc biệt và dấu câu thừa, chỉ giữ lại các ký tự chữ cái tiếng Anh, chữ số và khoảng trắng để làm sạch mạch văn bản.

Phase 2. Emoji Translation

- Biểu tượng cảm xúc (Emoji) chứa hàm lượng sắc thái tâm lý và biểu cảm đặc thù rất cao của người dùng mạng xã hội. Thay vì loại bỏ hoàn toàn làm mất mát ngữ cảnh nghiêm trọng, hệ thống sử dụng một bộ từ điển ánh xạ chuyên biệt (emoji_en.json).
- Mỗi emoji sẽ được thay thế bằng một cụm từ tiếng Anh chuẩn hóa tương ứng thể hiện trực tiếp trạng thái cảm xúc (ví dụ: Biểu tượng smiling-face được ánh xạ thành cụm từ *"passionate/adorable"*, biểu tượng pouting-face được ánh xạ thành từ *"angry/mad"*).
- Kỹ thuật này giúp cấu trúc hóa các biểu tượng phi văn bản thành các token mang tính semantic cao, hỗ trợ các tầng Attention Layers tính toán chính xác mối liên kết ngữ cảnh.

Phase 3. Slang & Abbreviation Mapping

- Văn phong giao tiếp trực tuyến thường xuyên sử dụng từ lóng (slang) hoặc viết tắt các cụm từ thông dụng, điều này gây cản trở nghiêm trọng đến khả năng hiểu của mô hình. Hệ thống tích hợp bộ từ điển slang_en.json để khôi phục văn bản về dạng tường minh.
- Các mã từ viết tắt phổ biến trên Twitter như *"im"*, *"ill"*, *"dont"*, *"cant"*, *"u"*, *"ur"* sẽ được chuẩn hóa chính xác về dạng ngữ pháp chuẩn mực tương ứng bao gồm: *"i am"*, *"i will"*, *"do not"*, *"cannot"*, *"you"*, *"your"*.
- Bước xử lý này giúp thu hẹp khoảng cách phân phối ngôn ngữ mạng xã hội với corpus tiếng Anh chuẩn, cho phép mô hình khai thác triệt để tri thức nền tảng đã tích lũy từ giai đoạn pre-training.

Phase 4. Repeated Characters Normalization

- Người dùng mạng xã hội có xu hướng lặp lại nhiều lần một ký tự liên tiếp để nhấn mạnh hoặc phóng đại cường độ cảm xúc (ví dụ: *"loooove"*, *"soooo happyyyyyy"*). Hiện tượng này vô tình sinh ra các từ nằm ngoài từ điển (Out-Of-Vocabulary) và làm loãng mật độ thông tin.
- Đường ống áp dụng thuật toán khớp mẫu bằng Regex để thu gọn các ký tự trùng lặp liên tiếp (xuất hiện từ 2 lần trở lên) về lại đúng 1 ký tự nguyên bản mẫu mực (ví dụ: *"loooove"* → *"love"*, *"happyyyyyy"* → *"happy"*).

Phase 5. Mã hóa từ vựng và Tokenization

Sau khi chuỗi văn bản thô được làm sạch trọn vẹn ở định dạng văn bản chuẩn, dữ liệu ngữ cảnh sẽ được chuyển giao cho bộ mã hóa Byte-Pair Encoding (BPE) cấp độ byte mặc định của kiến trúc RoBERTa:


- Bộ từ vựng hệ thống sở hữu kích thước cố định gồm **50,265 token**.
- Mô hình tự động đóng gói chuỗi văn bản bằng cách chèn token đặc biệt $\langle s \rangle$ vào vị trí khởi đầu câu (vị trí này lưu trữ vector trạng thái ẩn h_{start} mang thông tin tóm tắt toàn bộ câu để đưa vào đầu phân loại chuỗi) và cấu hình token $\langle /s \rangle$ vào vị trí kết thúc chuỗi ngữ cảnh.
- Các chuỗi token hóa được thiết lập chiều dài giới hạn tối đa $max_length = 128$ thông qua cơ chế cắt ngắn (truncation) đối với các câu quá dài và chèn thêm các mã đệm ẩn $\langle pad \rangle$ (padding) đối với các câu ngắn, đảm bảo tính đồng nhất tuyệt đối về mặt kích thước hình học cho ma trận tensor đầu vào.

Toàn bộ quy trình tiền xử lý sâu và mã hóa token này được thực thi song song đa luồng ($num_proc=4$) và áp dụng đồng bộ, nhất quán trên cả 3 phân khúc dữ liệu đã phân tách: **375,128 mẫu** thuộc tập Train, **20,840 mẫu** thuộc tập Validation và **20,841 mẫu** thuộc tập Test, giúp ngăn chặn hoàn toàn hiện tượng rò rỉ thông tin (Data Leakage).

4 Kiến trúc RoBERTa cho nhận diện cảm xúc

Kiến trúc RoBERTa được sử dụng để chuyển đổi văn bản đầu vào thành phân phối xác suất trên sáu lớp cảm xúc. Quy trình xử lý tổng quát gồm các bước: mã hóa văn bản thành token, ánh xạ token sang vector nhúng, xử lý qua các tầng Transformer Encoder, trích xuất vector đại diện toàn câu và đưa qua đầu phân loại chuỗi.

Kiến trúc RoBERTa



Hình 1: Kiến trúc RoBERTa

4.1 Phân mảnh từ vựng và mã hóa token

Khi một câu văn bản được đưa vào hệ thống, bộ mã hóa Byte-Pair Encoding (BPE) cấp độ byte của RoBERTa sẽ chia câu thành các tokens. Bộ từ vựng Vocabulary của RoBERTa-base có 50,265 token. Mô hình tự động bổ sung token đặc biệt $\langle s \rangle$ ở đầu chuỗi và $\langle /s \rangle$ ở cuối chuỗi. Do đó, một văn bản thô được biểu diễn dưới dạng:

<s> Nội dung câu đầu vào </s>

4.2 Tầng nhúng và biểu diễn không gian (Embedding Layer)

Sau khi mã hóa, các từ (token) không được đưa trực tiếp vào mô hình mà được ánh xạ thành các vector số thực thông qua bảng nhúng từ vựng. Đây là không gian ẩn (hidden space) chứa các đặc trưng ngữ nghĩa của từ. Với cấu hình RoBERTa-base, kích thước vector ẩn là $d = 768$.

Trong BERT gốc, quá trình pre-training có một tác vụ là Next Sentence Prediction (NSP) cần thực hiện nhúng phân đoạn câu (`token_type_ids`). Khác với BERT, trong RoBERTa tác vụ NSP không thực sự hiệu quả và đã loại bỏ nó, nên tầng nhúng của nó đơn giản hơn, không cần nhúng phân đoạn (segment embedding). Biểu diễn đầu vào chủ yếu là tổng hợp của Token Embedding (ngữ nghĩa của từ) và Position Embedding (nhúng vị trí tuyệt đối), giúp mô hình giữ lại thông tin về thứ tự cú pháp trong câu.

4.3 Cơ chế Multi-Head Self-Attention

Phần lõi của RoBERTa-base gồm 12 lớp Transformer Encoder xếp chồng. Mỗi lớp sử dụng cơ chế Multi-Head Self-Attention với 12 đầu song song. Cơ chế này cho phép mỗi token trong chuỗi học mối liên hệ ngữ cảnh với mọi token khác, kể cả khi chúng cách rất xa nhau trong câu.

Tại mỗi đầu chú ý, các ma trận truy vấn (Query – Q), khóa (Key – K) và giá trị (Value – V) được tính thông qua phép chiếu tuyến tính. Công thức attention được tính như sau:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- Q, K, V : Đầu vào được nhân với các trọng số để tạo ra 3 ma trận Query (truy vấn), Key (khóa), và Value (giá trị). Phép nhân QK^T tính toán độ tương đồng giữa các token.
- **Hệ số $\sqrt{d_k}$** : Với $d_k = 64$ ($768 \div 12$), đây là bước **scaling**. Nếu không chia cho $\sqrt{d_k}$, tích vô hướng QK^T có thể mang giá trị rất lớn. Khi đẩy các giá trị cực lớn này qua hàm Softmax, đạo hàm (gradient) sẽ tiến sát về 0 (vanishing gradient), khiến mô hình không thể học được trong quá trình lan truyền ngược (backpropagation).
- **Feed-Forward & GeLU**: Sau khi ghép nối kết quả từ 12 đầu chú ý, dữ liệu đi qua một mạng nơ-ron truyền thẳng sử dụng hàm kích hoạt **GeLU** (Gaussian Error Linear Unit), một hàm có đường cong mượt hơn ReLU, giúp hội tụ tốt hơn trong các mô hình ngôn ngữ lớn.

4.4 Đầu phân loại chuỗi

Sau 12 lớp Transformer Encoder, mô hình thu được chuỗi các vector trạng thái ẩn đã mang thông tin ngữ cảnh. Đối với tác vụ phân loại toàn câu, hệ thống trích xuất vector tại vị trí token đầu tiên $\langle \mathbf{s} \rangle$, ký hiệu là $h_{\text{start}} \in \mathbb{R}^{768}$. Vector này được xem như biểu diễn tóm tắt của toàn bộ câu.

Vector h_{start} được đưa vào đầu phân loại chuỗi gồm các thành phần sau:

- Lớp tuyến tính trung gian chiếu vector 768 chiều sang không gian ẩn cùng kích thước.
- Hàm kích hoạt tanh để phi tuyến hóa không gian đặc trưng.
- Lớp Dropout với tỷ lệ thường dùng là 0.1 nhằm giảm nguy cơ quá khớp.
- Lớp chiếu tuyến tính cuối cùng ánh xạ vector ẩn sang 6 giá trị logits tương ứng với 6 lớp cảm xúc.

Nếu vector logits đầu ra được ký hiệu là $z = [z_0, z_1, z_2, z_3, z_4, z_5]^T$, xác suất dự đoán của lớp thứ i được tính bằng hàm Softmax:

$$\hat{y}_i = \frac{e^{z_i}}{\sum_{j=1}^6 e^{z_j}}$$

Nhãn cảm xúc cuối cùng được chọn theo chỉ số có xác suất lớn nhất:

$$\hat{c} = \arg \max_i \hat{y}_i$$

5 Thiết kế thực nghiệm và tối ưu hóa siêu tham số

Quá trình fine-tuning được thiết kế nhằm chuyển giao tri thức ngôn ngữ đã học trong giai đoạn tiền huấn luyện sang tác vụ phân loại cảm xúc chuyên biệt trên không gian văn bản mạng xã hội Twitter. Mô hình sử dụng bộ tối ưu hóa AdamW, một biến thể của Adam có tích hợp cơ chế tách biệt phần suy giảm trọng số (decoupled weight decay) khỏi các bước cập nhật gradient dựa trên moment. Đặc tính này giúp ổn định biên độ trọng số của các tầng mạng Transformer sâu, ngăn chặn hiện tượng vanishing gradient và tăng tốc độ hội tụ của hệ thống.

5.1 Thiết lập Baseline Hyperparameters

Trước khi tiến hành tìm kiếm tự động, một không gian siêu tham số nền tảng đã được định hình dựa trên các khuyến nghị thực nghiệm dành cho kiến trúc RoBERTa-base. Các giá trị này đóng vai trò thiết lập ranh giới vận hành ban đầu cho mô hình.

Bảng 2: Các siêu tham số chính trong quá trình huấn luyện

Siêu tham số	Giá trị thực nghiệm	Ý nghĩa
Learning Rate	2×10^{-5} hoặc 5×10^{-5}	Giữ tốc độ học ở mức nhỏ để tránh phá vỡ các đặc trưng ngôn ngữ vĩ mô đã học từ giai đoạn pre-training.
Batch Size	32 hoặc 64	Quy định số lượng mẫu xử lý đồng thời, cân bằng giữa độ mịn của hướng đi gradient và giới hạn bộ nhớ phần cứng
Epochs	5–10 chu kỳ huấn luyện	Xác định số lượt lặp để mô hình học sâu sắc các đặc trưng cảm xúc mà không huấn luyện quá lâu gây ra hiện tượng overfitting.
Weight Decay	0.01–0.03	Tạo ràng buộc chuẩn hóa L2 trực tiếp trên các trọng số, giúp cải thiện khả năng tổng quát hóa.
Warmup Steps	500 bước	Tăng dần learning rate từ 0 lên cực đại ở giai đoạn đầu giúp ổn định các lớp phân loại mới.
Dropout	0.1	Vô hiệu hóa ngẫu nhiên 10% neuron tại các lớp nhúng và đầu phân loại để tăng độ bền vững, chống phụ thuộc dữ liệu
Scheduler	Linear hoặc Cosine	Giảm dần learning rate sau warm-up để mô hình hội tụ ổn định hơn.

5.2 Hyperparameter Tuning

Bên cạnh việc thử nghiệm cấu hình thủ công, công cụ Optuna được tích hợp trực tiếp vào quá trình huấn luyện để tự động hóa quá trình tìm kiếm tổ hợp siêu tham số tối ưu. Thông qua cơ chế tìm kiếm thông minh kết hợp thuật toán cắt tỉa (pruning) các cấu hình kém hiệu quả, Optuna hỗ trợ xác định dynamic interaction tốt nhất giữa các tham số `learning_rate`, `weight_decay` và `warmup_ratio`.

Do phân phối nhãn của tập dữ liệu [dair-ai/emotion](#) mang đặc tính mất cân bằng lớp nghiêm trọng (các lớp đa số như joy và sadness chiếm tỷ trọng áp đảo nhãn thiểu số như love và surprise), hàm mục tiêu (Objective Value) của quá trình Tuning không thể sử dụng độ chính xác Accuracy đơn thuần. Nhằm đảm bảo mô hình đạt hiệu năng phân tách đồng đều trên mọi trạng thái tâm lý, đồ án thiết kế hàm mục tiêu tối ưu hóa bằng tổng gộp của cả Accuracy và chỉ số Macro F_1 -score thu được trên tập Validation Set:

$$\text{Objective Value} = \text{Accuracy} + \text{Macro } F_1\text{-score}$$

Để quá trình Tuning diễn ra nhanh chóng và hiệu quả, thực nghiệm quét không gian

được triển khai trên một tập con trích mẫu đại diện (gồm 37,512 mẫu huấn luyện và 6,252 mẫu đánh giá), giới hạn trong 2 epochs mỗi lượt chạy. Hệ thống thực hiện hoàn chỉnh 5 lượt thử nghiệm (Trials 0 đến 4) với các kết quả ghi nhận như sau:

- **Trial 0:** Đạt giá trị hàm mục tiêu 1.8396 với cấu hình siêu tham số: $lr = 1.432 \times 10^{-5}$, $weight_decay = 0.0663$, $warmup_ratio = 0.0737$.
- **Trial 1 (Tổ hợp tối ưu nhất):** Đạt đỉnh hiệu năng với giá trị mục tiêu cao nhất là 1.8482. Tại điểm hội tụ của chu kỳ này, mô hình đạt độ chính xác `eval_accuracy` là 0.9368 và điểm `eval_f1` (Macro) đạt 0.9114. Tổ hợp siêu tham số chiến thắng bao gồm:
 - `learning_rate`: 2.1286×10^{-5}
 - `weight_decay`: 0.0866
 - `warmup_ratio`: 0.1265
- **Trial 2:** Đạt giá trị hàm mục tiêu 1.8460 với các tham số: $lr = 1.893 \times 10^{-5}$, $weight_decay = 0.0195$, $warmup_ratio = 0.0091$.
- **Trial 3:** Đạt giá trị hàm mục tiêu 1.8465 với các tham số: $lr = 3.109 \times 10^{-5}$, $weight_decay = 0.0714$, $warmup_ratio = 0.0817$.
- **Trial 4:** Đạt giá trị hàm mục tiêu 1.8450 với các tham số: $lr = 1.938 \times 10^{-5}$, $weight_decay = 0.0679$, $warmup_ratio = 0.1551$.

Phân tích kết quả Tuning: Thử nghiệm từ Optuna vạch trần một quy luật quan trọng: hệ số suy giảm trọng số (`weight_decay`) đóng vai trò quyết định đến năng lực tổng quát hóa của RoBERTa đối với ngữ cảnh mạng xã hội Twitter. Tại Trial 1, khi `weight_decay` được siết chặt lên mức rất cao (0.0866), vượt xa biên độ thiết lập nền tảng ban đầu (0.01 – 0.03), mô hình lập tức đạt điểm số tối ưu. Ràng buộc kiểm soát này ngăn các ma trận trọng số bám đuổi các chi tiết nhiễu của tập Train, nâng cao tính tổng quát hóa trên tập dữ liệu chưa biết.

5.3 Model Training

Sau khi xác định được bộ siêu tham số lý tưởng từ quá trình Tuning, cấu hình tối ưu này chính thức được áp dụng vào file cấu hình hệ thống configs/train.yaml để tiến hành giai đoạn huấn luyện toàn vẹn.

Bảng 3: Cấu hình siêu tham số tối ưu (Best Hyperparameters)

Siêu tham số	Giá trị
learning_rate	2.128×10^{-5}
weight_decay	0.0866
warmup_ratio	0.1265
train_batch_size	32
eval_batch_size	32
num_epochs	3
early_stopping_patience	1
fp16	True

Quá trình huấn luyện bản chính thức được thực thi trên quy mô toàn bộ **375,128 mẫu** của tập Train. Mô hình được thiết lập chạy trong **3 chu kỳ** (epochs) toàn vẹn. Để kiểm soát chặt chẽ ranh giới hội tụ và ngăn ngừa hiện tượng overfitting ở giai đoạn cuối, cơ chế EarlyStoppingCallback được kích hoạt với tham số **patience=1**. Hệ thống sẽ liên tục giám sát điểm Macro F_1 -score trên tập Validation sau mỗi epoch; nếu chỉ số này có xu hướng sụt giảm hoặc đứng im, quá trình huấn luyện sẽ được dừng lại lập tức và cấu hình trọng số tốt nhất (*Best Model Weights*) sẽ được đóng gói phục vụ giai đoạn đánh giá thực tế tiếp theo.


6 Kết quả thực nghiệm và phân tích đánh giá

Sau khi hoàn tất fine-tuning và lựa chọn cấu hình siêu tham số tốt nhất, mô hình được đánh giá trên tập kiểm thử gồm 20,841 mẫu. Các chỉ số thường được sử dụng gồm Accuracy, Precision, Recall và F1-score. Trong đó, Macro F1-score đặc biệt quan trọng vì chỉ số này tính trung bình F1-score trên từng lớp mà không phụ thuộc vào số lượng mẫu của mỗi lớp.

Ma trận nhầm lẫn (*Confusion Matrix*) được sử dụng để phân tích chi tiết các lỗi phân loại giữa các cặp cảm xúc. Với sáu lớp cảm xúc, ma trận có kích thước 6×6 , trong đó phần tử tại hàng i , cột j biểu thị số mẫu thật thuộc lớp i nhưng được mô hình dự đoán là lớp j . Các giá trị nằm trên đường chéo chính thể hiện số dự đoán đúng, còn các giá trị ngoài đường chéo cho biết kiểu nhầm lẫn của mô hình.

Về mặt kỳ vọng, các lớp có biểu hiện ngữ nghĩa gần nhau dễ xảy ra nhầm lẫn hơn. Chẳng hạn, *sadness* và *fear* đều có sắc thái tiêu cực; *joy* và *love* đều gắn với cảm xúc tích cực; trong khi *surprise* thường khó nhận diện do số lượng mẫu ít và có thể xuất hiện trong

cả ngữ cảnh tích cực lẫn tiêu cực. Do đó, phân tích ma trận nhầm lẫn không chỉ phản ánh độ chính xác tổng thể mà còn giúp nhận diện những điểm yếu cụ thể của hệ thống.



Hình 2: Ma trận nhầm lẫn của mô hình RoBERTa trên tập kiểm thử

Dưới đây là Classification Report của mô hình RoBERTa trên tập Test (dựa trên các kết quả thu được trong thư mục `model/results`):

Lớp cảm xúc	Precision	Recall	F1-Score
Sadness	0.9974	0.9593	0.9780
Joy	0.9985	0.9195	0.9574
Love	0.7732	1.0000	0.8721
Anger	0.9446	0.9520	0.9483
Fear	0.9068	0.9095	0.9082
Surprise	0.7567	0.9987	0.8610
Trung bình (Macro avg)	0.8962	0.9565	0.9208
Trung bình có trọng số (Weighted avg)	0.9525	0.9440	0.9458
Độ chính xác tổng (Accuracy)	-	-	0.9440

Đánh giá chuyên sâu về kết quả toán học

- **Độ chính xác tổng thể ấn tượng:** Chỉ số Accuracy tổng đạt **94.40%**, khẳng định ưu thế vượt trội của kiến trúc tối ưu hóa RoBERTa so với các giải pháp học máy cũ truyền thống.
- **Sự thống trị của các lớp đa số:** Lớp **Sadness** và **Joy** đạt điểm F1-score cực kỳ cao, lần lượt là **97.80%** và **95.74%**. F1-score là sự cân bằng giữa việc đoán đúng và không bỏ sót. F1-score cao chứng tỏ mô hình nhận diện hai cảm xúc này cực kỳ tốt, ổn định và hiếm khi nhầm lẫn chúng với các cảm xúc khác. Điều này cho thấy mô hình đã học được một biểu trưng không gian đặc trưng vô cùng sắc bén và mạch lạc cho hai trạng thái tâm lý phổ biến này.
- **Đặc tính phân loại cực đoan của lớp Love:** Lớp **Love** ghi nhận chỉ số Recall tuyệt đối là **100%** (dự đoán đúng toàn bộ các mẫu thực tế trong số 1,735 mẫu) nhưng lại có Precision thấp nhất là **77.32%**. Điều này là do mô hình đã phân loại nhầm tới 509 mẫu thực tế là **Joy** thành **Love**. Vấn đề này xuất phát từ bản chất ngôn ngữ học: tình yêu thương và niềm vui thường chia sẻ chung rất nhiều biểu thị ngữ cảnh tích cực cường độ cao.
- **Thách thức Surprise:** Lớp **Surprise** ghi nhận Recall cực cao **99.87%** (chỉ bỏ sót đúng 1 mẫu) nhưng Precision chỉ đạt **75.67%** do bị nhiễu bởi 202 mẫu **Fear** bị dự đoán nhầm thành **Surprise**. Sự bất ngờ và nỗi sợ hãi đều kích hoạt các phản ứng từ vụng liên quan đến trạng thái chấn động, sửng sốt hoặc kinh ngạc, tạo nên vùng chồng lấn ngữ nghĩa rất lớn trong không gian nhúng của Transformer.

7 Triển khai hệ thống và vận hành thực tế

Sau khi hoàn thành quá trình huấn luyện và đánh giá mô hình, đầu tiên mô hình được upload lên nền tảng Huggingface [tazuneru/roberta-emotion-english](https://huggingface.co/tazuneru/roberta-emotion-english). Qua đó, hệ thống được triển khai dưới dạng ứng dụng web hoàn chỉnh theo kiến trúc ba tầng (*3-Tier Architecture*) kết hợp mô hình *Client-Server*. Kiến trúc này cho phép tách biệt giao diện người dùng, tầng xử lý nghiệp vụ và dịch vụ suy luận mô hình học máy nhằm tăng khả năng mở rộng, bảo trì và triển khai thực tế.

7.1 Triển khai giao diện người dùng

Giao diện người dùng được xây dựng bằng *Next.js* và triển khai trên nền tảng *Vercel*. Toàn bộ mã nguồn frontend được đặt trong thư mục `emotion-recognition-app/apps/web`. Quá trình build sử dụng cơ chế monorepo, trong đó package dùng chung được biên dịch trước khi biên dịch ứng dụng web.

URL triển khai hiện tại:

<https://emotion-recognition-v2-five.vercel.app>

Frontend giao tiếp với backend thông qua biến môi trường `NEXT_PUBLIC_API_URL`, cho phép thay đổi địa chỉ máy chủ mà không cần sửa đổi mã nguồn. Ngoài ra, cấu hình `transpilePackages` được sử dụng để bảo đảm các package dùng chung được biên dịch chính xác trong môi trường trình duyệt.

7.2 Triển khai Backend API

Tầng xử lý nghiệp vụ được xây dựng bằng *Node.js*, *Express* và *TypeScript*, sau đó triển khai trên nền tảng *Railway*. Backend chịu trách nhiệm tiếp nhận yêu cầu từ người dùng, xác thực dữ liệu đầu vào, giao tiếp với dịch vụ suy luận mô hình và lưu trữ lịch sử phân tích.

URL triển khai hiện tại:

<https://charming-abundance-production-eda1.up.railway.app>

Để bảo đảm khả năng hoạt động ổn định trong môi trường thực tế, hệ thống sử dụng các biến môi trường phục vụ kết nối cơ sở dữ liệu PostgreSQL, Redis, dịch vụ mô hình và cấu hình CORS. Backend được cấu hình `trust proxy` nhằm hỗ trợ chính xác việc giới hạn tốc độ truy cập (*rate limiting*) khi hoạt động phía sau reverse proxy của Railway.

7.3 Triển khai dịch vụ mô hình học máy

Dịch vụ suy luận mô hình được tách riêng thành một *FastAPI Model Service* và triển khai trên nền tảng *Hugging Face Spaces*. Việc tách biệt mô hình khỏi backend giúp giảm độ phụ thuộc giữa các thành phần và tạo điều kiện mở rộng hệ thống trong tương lai.

URL triển khai hiện tại:

<https://lcphuc-emotion-model-api.hf.space>

Hệ thống này đảm bảo hỗ trợ ngôn ngữ tiếng Anh thông qua mô hình đã upload trước đó [tazuneru/roberta-emotion-english](#).

Để tối ưu tài nguyên bộ nhớ, mô hình tiếng Anh được nạp theo cơ chế *lazy loading*, tức chỉ tải khi xuất hiện yêu cầu suy luận đầu tiên. Giải pháp này giúp giảm đáng kể mức sử dụng RAM và thời gian khởi động trên hạ tầng miễn phí của Hugging Face.

Do đặc điểm của nền tảng miễn phí, dịch vụ có thể chuyển sang trạng thái ngủ (*sleep mode*) sau một khoảng thời gian không hoạt động. Khi đó, yêu cầu đầu tiên sẽ kích hoạt quá trình *cold start*, bao gồm tải mô hình và khởi tạo bộ nhớ, thường mất từ một đến ba phút trước khi hệ thống sẵn sàng phục vụ.

Trong quá trình vận hành, dịch vụ FastAPI không lưu trữ cố định trọng số mô hình trong mã nguồn mà tải trực tiếp từ Hugging Face thông qua thư viện `transformers`. Cơ chế này giúp đơn giản hóa việc cập nhật phiên bản mô hình và giảm kích thước repository

triển khai. Khi hệ thống khởi động, các tokenizer và mô hình được nạp bằng phương thức `from_pretrained()`, sau đó được lưu trong bộ nhớ đệm cục bộ để phục vụ suy luận.

Mã nguồn phục vụ mô hình được triển khai độc lập dưới dạng Hugging Face Space tại địa chỉ:

<https://huggingface.co/spaces/lcphuc/emotion-model-api>

Trong cấu hình hiện tại, mô hình tiếng Anh được tải theo cơ chế *lazy loading*. Chiến lược này giúp giảm mức tiêu thụ bộ nhớ RAM và rút ngắn thời gian khởi động của dịch vụ, đặc biệt khi triển khai trên hạ tầng miễn phí có giới hạn tài nguyên tính toán.


7.4 Cơ sở dữ liệu và hàng đợi xử lý

Hệ thống sử dụng *Railway PostgreSQL* làm cơ sở dữ liệu chính để lưu trữ lịch sử phân tích cảm xúc, thông tin tác vụ xử lý và các dữ liệu vận hành khác. Các bản migration được quản lý bằng *Prisma ORM* và tự động áp dụng khi dịch vụ khởi động.

Bên cạnh đó, *Railway Redis* được sử dụng làm tầng bộ nhớ đệm và hàng đợi thông điệp cho các tác vụ xử lý bất đồng bộ. Redis đóng vai trò quan trọng trong việc hỗ trợ *BullMQ*, cho phép xử lý các tệp CSV kích thước lớn hoặc các tác vụ nền mà không làm ảnh hưởng đến thời gian phản hồi của hệ thống.

7.5 Kiến trúc triển khai tổng thể

Kiến trúc triển khai cuối cùng của hệ thống được mô tả như sau:



Kiến trúc này bảo đảm khả năng mở rộng theo từng thành phần, cho phép nâng cấp riêng biệt giao diện người dùng, backend hoặc mô hình học máy mà không ảnh hưởng đến toàn bộ hệ thống.

8 Kết luận

Đồ án đã xây dựng hệ thống nhận diện cảm xúc văn bản tiếng Anh dựa trên mô hình RoBERTa và tập dữ liệu [dair-ai/emotion](#). Hệ thống thực hiện bài toán phân loại sáu lớp cảm xúc gồm *sadness*, *joy*, *love*, *anger*, *fear* và *surprise*. Quy trình thực nghiệm bao

gồm phân tách dữ liệu theo tỷ lệ 90%–5%–5%, fine-tuning mô hình RoBERTa, tối ưu hóa siêu tham số bằng AdamW và Optuna, sau đó đánh giá kết quả trên tập kiểm thử độc lập.

Kết quả kỳ vọng cho thấy hướng tiếp cận dựa trên Transformer có khả năng khai thác tốt thông tin ngữ cảnh và sắc thái biểu cảm trong văn bản mạng xã hội. Tuy nhiên, bài toán vẫn còn thách thức do dữ liệu mất cân bằng lớp, ngôn ngữ Twitter có tính phi chuẩn cao và một số cảm xúc có ranh giới ngữ nghĩa mơ hồ. Trong các hướng phát triển tiếp theo, hệ thống có thể được cải thiện bằng cách cân bằng dữ liệu, tăng cường dữ liệu cho các lớp hiếm, thử nghiệm thêm các mô hình lớn hơn và phân tích sâu hơn các mẫu dự đoán sai.

9 References

- [1] **StatQuest with Josh Starmer.** *Transformer Neural Networks, ChatGPT's foundation, Clearly Explained!!!* [Online Video]: <https://youtu.be/zxQyTK8quyY?si=26G7Er1JyJEoDGSU>.

Video này cung cấp cái nhìn trực quan và chi tiết về nền tảng cốt lõi của mô hình Transformer, bao gồm cơ chế nhúng từ (Word Embedding), mã hóa vị trí (Positional Encoding) bằng hàm lượng giác, và cách thức hoạt động của cơ chế Self-Attention thông qua phép toán tích vô hướng (Dot Product).

- [2] **Stanford Online.** *RoBERTa / Stanford CS224U Natural Language Understanding / Spring 2021* [Online Video]: https://www.youtube.com/watch?v=EZMOBbu_5b8.

Bài giảng chuyên sâu thuộc khóa học của Đại học Stanford, phân tích các cải tiến tối ưu hóa mang tính đột phá của kiến trúc RoBERTa so với BERT nguyên bản, đặc biệt là kỹ thuật Dynamic Masking và việc loại bỏ tác vụ dự đoán câu tiếp theo (Next Sentence Prediction).

- [3] **Stanford Online.** *Stanford CME295 Transformers & LLMs / Autumn 2025 / Lecture 1 - Transformer* [Online Video]: <https://www.youtube.com/watch?v=Ub3GoFaUcds>.

Bài giảng nền tảng thuộc khóa học CME 295 của Đại học Stanford, cung cấp kiến thức toàn diện về lịch sử Xử lý Ngôn ngữ Tự nhiên (NLP) và sự phát triển của mô hình ngôn ngữ. Cụ thể, tài liệu diễn giải sự chuyển dịch từ các mạng nơ-ron tuần tự như RNN và LSTM sang kiến trúc Transformer, tập trung phân tích ưu điểm vượt trội của cơ chế Self-Attention trong việc giải quyết vấn đề phụ thuộc xa (long-range dependencies) và tối ưu hóa tính toán song song.

- [4] **Hugging Face.** *RoBERTa-base Model Card.* [Online]: <https://huggingface.co/FacebookAI/roberta-base>.

Trang tài liệu chính thức lưu trữ mã nguồn cấu trúc và tập trọng số (pre-trained weights) của mô hình `roberta-base`. Đây là nền tảng được đề án sử dụng để nhúng

vào thư viện **transformers** nhằm thực hiện quá trình huấn luyện lại (Fine-tuning) trên tập dữ liệu cảm xúc.

- [5] **Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V.** (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. arXiv preprint arXiv:1907.11692: <https://arxiv.org/abs/1907.11692>.

Bài báo khoa học gốc từ Meta AI (Facebook AI) giới thiệu mô hình RoBERTa. Tài liệu chứng minh rằng việc huấn luyện BERT với kích thước batch lớn hơn (Hyperparameter tuning), thời gian lâu hơn trên tập dữ liệu thô quy mô lớn, kết hợp mã hóa Byte-Pair Encoding (BPE) ở cấp độ byte giúp nâng cao đáng kể hiệu năng phân loại văn bản.